Resumen de “Attention Is All You Need”

📌 Objetivo del artículo

Proponer una nueva arquitectura llamada **Transformer**, que elimina por completo el uso de redes recurrentes (RNNs) y convolucionales (CNNs), utilizando únicamente mecanismos de **atención** para procesar secuencias de datos, como el lenguaje natural.

🏗️ Arquitectura del Transformer

1. Codificador-Decodificador (Encoder-Decoder)

- El modelo se divide en dos partes:
    - **Codificador**: procesa la secuencia de entrada.
    - **Decodificador**: genera la secuencia de salida.
- Ambos están compuestos por bloques repetidos que contienen mecanismos de atención y capas feed-forward.

2. Mecanismo de Atención

- Introduce el concepto de **“Self-Attention”** (atención a uno mismo), que permite al modelo ponderar la importancia de cada palabra en una oración respecto a las demás.
- Fórmula clave:
  Attention(Q,K,V)=softmax(QKTdk)VAttention(*Q*,*K*,*V*)=softmax(*dkQKT*)*V*
  donde:
    - Q*Q*: consultas (queries)
    - K*K*: claves (keys)
    - V*V*: valores (values)
    - dk*dk*: dimensión de las claves

3. Multi-Head Attention

- En lugar de una sola atención, se usan múltiples “cabezas” de atención en paralelo para capturar diferentes relaciones semánticas.

4. Positional Encoding

- Como no hay recurrencia, se añade información de posición a los embeddings para que el modelo entienda el orden de las palabras.

⚙️ Ventajas del Transformer

- **Paralelización**: A diferencia de las RNNs, permite procesar todas las palabras de una secuencia al mismo tiempo.

- **Escalabilidad**: Se entrena más rápido y con mayor eficiencia en GPUs.
- **Mejor rendimiento**: Supera a modelos anteriores en tareas como traducción automática.

📈 Resultados

- El Transformer logró **mejores resultados** que modelos previos en tareas de traducción automática, como en el conjunto de datos WMT 2014 (Inglés ↔ Alemán y Francés).

🧩 Impacto

- Este trabajo sentó las bases para modelos como **BERT**, **GPT**, **T5**, entre otros.
- Cambió radicalmente el enfoque del NLP moderno, desplazando a las RNNs y CNNs.

Ejemplos de cómo funcionan distintos **pipelines** (secuencias de pasos) en modelos de aprendizaje profundo, especialmente en el contexto de **NLP**.

Tres ejemplos representativos:

1. Pipeline de un modelo Transformer clásico (como BERT o GPT)

Objetivo: Comprender o generar texto.

Pasos:

1. **Entrada de texto**
   → "El gato duerme en el sofá."
2. **Tokenización**
   → Se divide el texto en unidades (tokens):
   ["El", "gato", "duerme", "en", "el", "sofá", "."]
3. **Conversión a IDs**
   → Cada token se convierte en un número según un vocabulario.
4. **Embeddings**
   → Los IDs se transforman en vectores densos (representaciones numéricas).
5. **Codificación posicional**
   → Se añade información sobre el orden de las palabras.
6. **Capas del Transformer**
   → Se aplican múltiples capas de atención y redes feed-forward.
7. **Salida**
   - En BERT: vectores de contexto para cada palabra (útiles para clasificación, QA, etc.)
   - En GPT: predicción del siguiente token (útil para generación de texto)

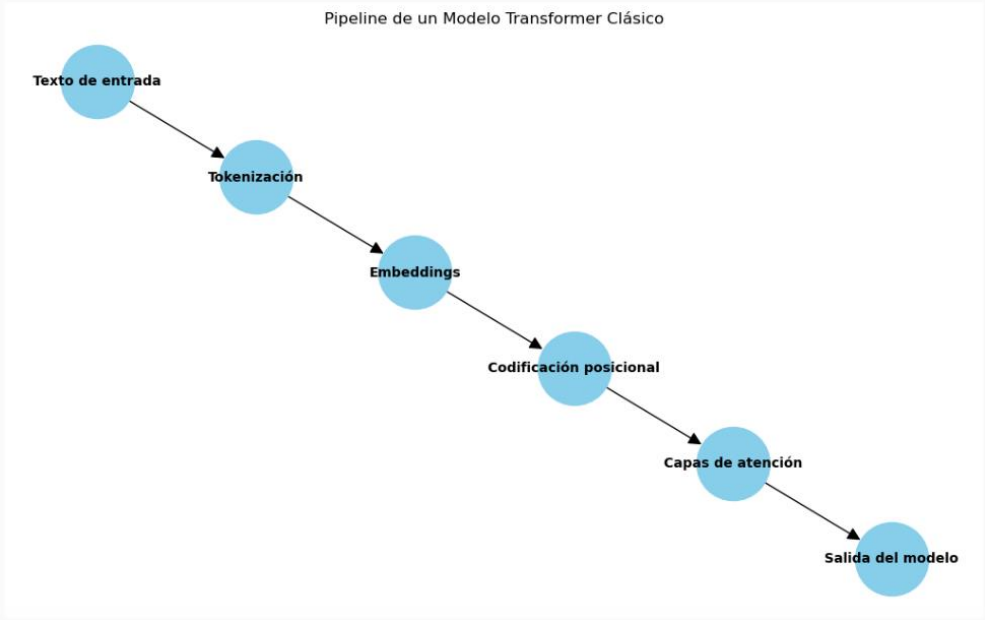

Explicación de cada paso:

1. **Texto de entrada**
   → La oración original que se quiere procesar.
2. **Tokenización**
   → Se divide el texto en unidades básicas (tokens).
3. **Embeddings**
   → Cada token se convierte en un vector numérico que representa su significado.
4. **Codificación posicional**
   → Se añade información sobre el orden de las palabras.
5. **Capas de atención**
   → El modelo aprende qué partes del texto son más relevantes para cada palabra.
6. **Salida del modelo**
   → Puede ser una predicción, una traducción, una respuesta, etc., según la tarea.

¿Qué lo diferencia de modelos como GPT o BERT?

Característica	Gemini	GPT (OpenAI)	BERT (Google)
Multimodalidad	Sí (texto, imagen, audio, video)	Limitado (GPT-4V: texto + imagen)	No (solo texto)
Entrenamiento	Desde cero como multimodal	Texto primero, luego visión	Solo texto
Tareas	Generación, razonamiento, análisis de datos, agentes	Generación de texto	Clasificación, QA, etc.
Velocidad	Flash: optimizado para baja latencia	GPT-4: más pesado	Rápido pero limitado

2. Pipeline de un modelo de clasificación de texto (como RoBERTa + capa final)

Objetivo: Clasificar un texto (por ejemplo, detectar si una reseña es positiva o negativa).

Pasos:

1. **Texto de entrada**
   → "Este producto es excelente."
2. **Tokenización y embeddings**
   → Igual que en el pipeline anterior.
3. **Modelo base (RoBERTa)**
   → Produce un vector de salida para cada token.
4. **[CLS] token**
   → Se toma el vector del token especial [CLS] como representación del texto completo.
5. **Capa densa + softmax**
   → Se pasa por una capa final que predice la clase (positivo o negativo).
6. **Salida**
   → "Positivo" con una probabilidad, por ejemplo, 92%.

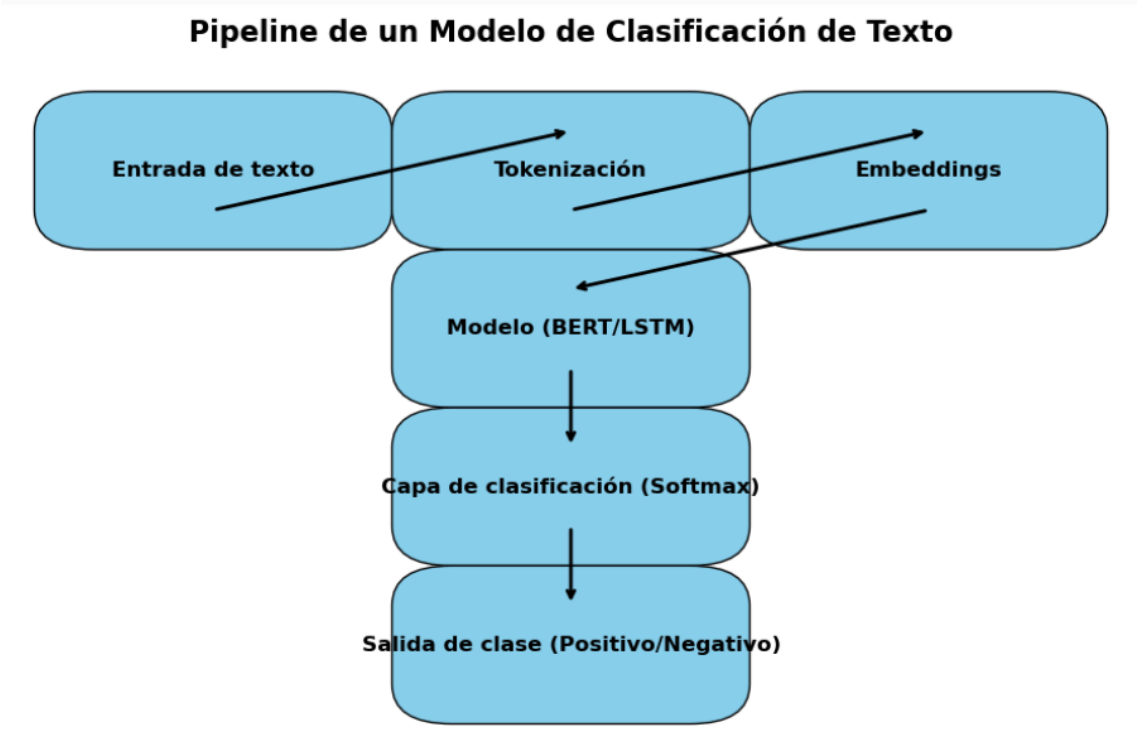

Explicación de cada paso:

1. Entrada de texto
   → Por ejemplo: "Este producto es excelente."
2. Tokenización
   → El texto se divide en tokens (palabras o subpalabras).
3. Embeddings
   → Cada token se convierte en un vector numérico que representa su significado.
4. Modelo (BERT, LSTM, etc.)
   → Procesa los embeddings para capturar el contexto y las relaciones entre palabras.
5. Capa de clasificación (Softmax)
   → Convierte la salida del modelo en probabilidades para cada clase.
6. Salida de clase
   → Por ejemplo: "Positivo" con una probabilidad del 92%.

3. Pipeline de un modelo de traducción automática (como el Transformer original)

Objetivo: Traducir una oración de un idioma a otro.

Pasos:

1. **Texto de entrada**
   → "The cat sleeps on the couch."
2. **Tokenización y embeddings (en inglés)**
   → Se procesan los tokens de entrada.
3. **Codificador (encoder)**
   → Produce una representación contextual de la oración.
4. **Decodificador (decoder)**
   → Genera la traducción palabra por palabra, usando atención sobre la salida del encoder.
5. **Generación de salida**
   → "El gato duerme en el sofá."

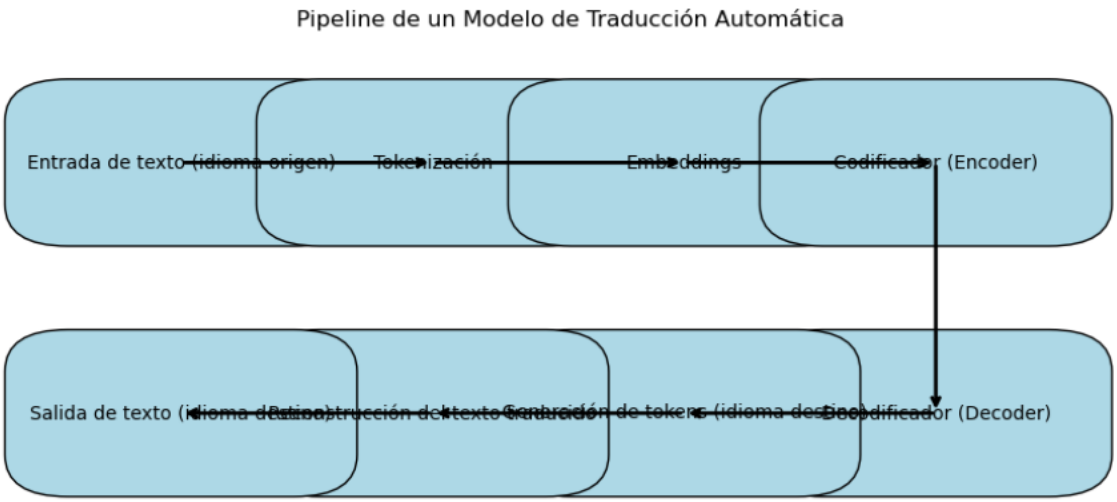

Explicación de cada paso:

1. **Entrada de texto (idioma origen)**
   → Por ejemplo: "The cat sleeps on the couch."
2. **Tokenización**
   → Se divide el texto en tokens (palabras o subpalabras).
3. **Embeddings**
   → Cada token se convierte en un vector numérico.
4. **Codificador (Encoder)**
   → Procesa los embeddings para capturar el significado del texto original.

5. **Decodificador (Decoder)**
   → Genera los tokens del idioma destino, uno por uno, usando la información del encoder.

6. **Generación de tokens (idioma destino)**
   → Se crean los tokens traducidos, como "El", "gato", "duerme"...

7. **Reconstrucción del texto traducido**
   → Se unen los tokens para formar la oración final.

8. **Salida de texto (idioma destino)**
   → Resultado: "El gato duerme en el sofá."

Pipeline general de Gemini (versión 2.5 Pro o Flash)

1. Entrada multimodal

Gemini puede recibir múltiples tipos de datos:

- Texto (como preguntas o instrucciones)
- Imágenes (fotos, diagramas)
- Audio (voz, sonidos)
- Video
- Código fuente

2. Preprocesamiento

Cada tipo de entrada se convierte en una representación numérica adecuada:

- Texto → tokens
- Imágenes → parches o embeddings visuales
- Audio → espectrogramas o embeddings acústicos
- Video → secuencias de frames + audio

3. Embeddings unificados

Todos los datos se transforman en un **espacio de representación común**, lo que permite que el modelo entienda relaciones entre modalidades (por ejemplo, texto que describe una imagen).

4. Modelo central (Transformer multimodal)

- Utiliza una arquitectura basada en Transformers, pero adaptada para manejar múltiples tipos de datos simultáneamente.
- Aplica mecanismos de atención cruzada entre modalidades (por ejemplo, texto que se refiere a una parte de una imagen).
- Puede razonar, generar código, responder preguntas, resumir videos, etc.

5. Salida

Dependiendo de la tarea, Gemini puede generar:

- Texto (respuestas, resúmenes, explicaciones)
- Código (en varios lenguajes)
- Audio (voz generada)
- Imágenes (en modelos con capacidad generativa)
- Combinaciones (por ejemplo, texto + imagen)

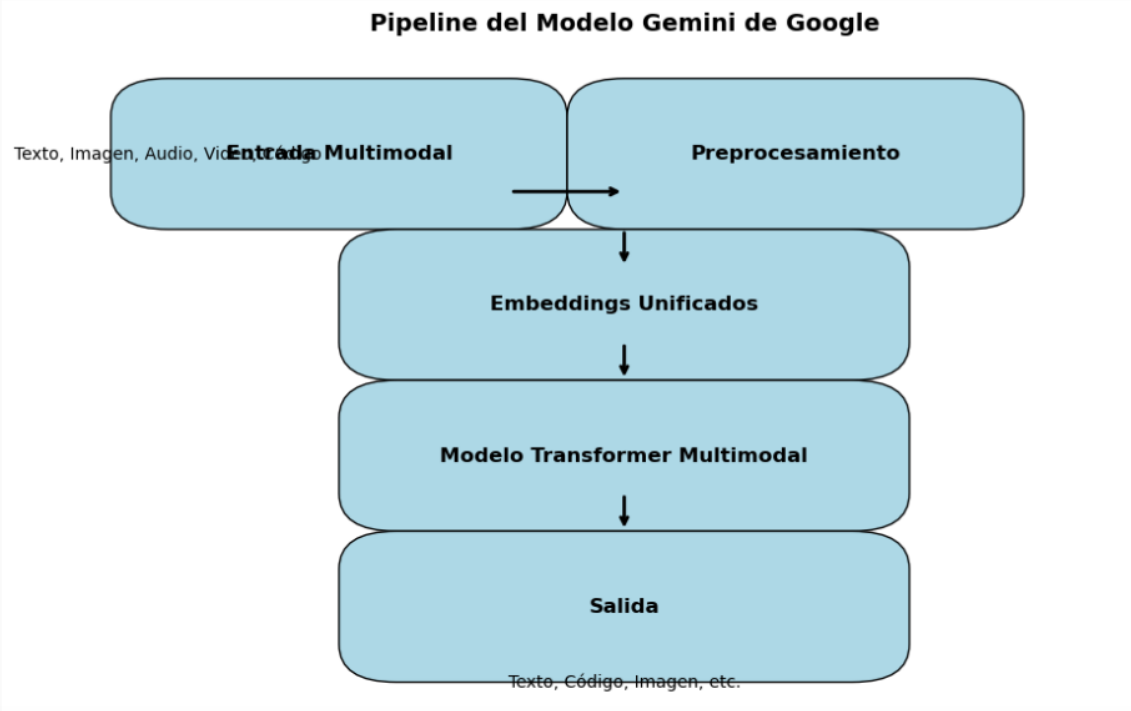

Explicación del flujo:

1. **Entrada Multimodal**
   → Gemini puede recibir texto, imágenes, audio, video y código como entrada.
2. **Preprocesamiento**
   → Cada tipo de dato se transforma en una representación numérica adecuada.
3. **Embeddings Unificados**
   → Todas las modalidades se integran en un espacio común de representación.
4. **Modelo Transformer Multimodal**
   → Procesa la información combinada usando atención cruzada entre modalidades.
5. **Salida**
   → Puede generar texto, código, imágenes, o una combinación según la tarea.